

# Proyecto Final: Corrector Ortográfico en Español

Instituto Tecnológico Autónomo de México  
Maestría en Ciencias en Computación  
Karen L. Poblete 116452  
Estadística Computacional

15 de diciembre de 2015

## 1. Introducción

Desde los años 90 se han diseñados diferentes modelos del lenguaje útiles para corregir la ortografía de textos. Los primeros y más importantes trabajos donde se basa este proyecto se basan en los artículos del laboratorio Bell de AT & T [1] [2] y el proyecto Watson de IBM [3]. Este método se basa en inferencia Bayesiana y modela los errores como un canal ruidoso, donde las faltas ortográficas son tratadas como si la palabra correcta pasa por un canal distorsionado por el ruido. El ruido es el causante de las faltas y el objetivo es descubrir la palabra que realmente fue pasada por el canal, que sería la palabra correcta.

El modelo de canal ruidoso se basa en la inferencia Bayesiana, ya que a partir de  $x$ , siendo la palabra errónea, se puede llegar a  $w$  que generó la palabra  $x$ . Siendo  $V$  el conjunto de las palabras disponibles en el lenguaje, el vocabulario, queremos encontrar  $w$  tal que la probabilidad  $P(w|x)$  es la más alta.

$$\hat{w} = \operatorname{argm\acute{a}x}_{w \in V} P(w|x)$$

Utilizando intuición Bayesiana se puede llegar a:

$$\hat{w} = \operatorname{argm\acute{a}x}_{w \in V} \frac{P(w|x)P(w)}{P(x)}$$

Donde  $P(x)$  se puede dejar fuera, ya que no cambia mucho de palabra a palabra, porque los errores cometidos tienen una probabilidad similar. Es decir, la mayor parte de los errores que se cometen están relacionados con omitir, agregar, trasponer o cambiar una letra y la probabilidad de tener sólo un cambio es el mismo; el 80 % de las faltas ortográficas son de este tipo y el 20 % tienen más de un cambio. Dada esta característica podemos entonces calcular mejor:

$$\hat{w} = \operatorname{argm\acute{a}x}_{w \in V} P(w|x)P(w)$$

Donde  $P(w|x)$  depende del modelo del canal, es decir, el modelo de los errores ortográficos y  $P(w)$  del modelo del lenguaje, el cual está basado en la frecuencia de las palabras. El modelo de lenguaje se puede generar por medio de n-gramas, es decir, hacer un análisis de la frecuencia de palabras individuales, unigramas. También se puede utilizar modelos de bigramas y trigramas, donde las probabilidades de aparición de una palabra dependen de las  $n$  palabras anteriores. En el caso de bigramas, la aparición de la palabra actual depende de la que está justo antes y para los trigramas de las dos que la anteceden. Los correctores léxicos basados en trigramas han mostrado mejores resultados cuando las palabras erróneas existen en el vocabulario y dependen de contexto. El contexto puede estar representado por Cadenas de Markov, donde el estado actual, que sería la palabra en error depende de la palabra pasada. Este proyecto se relaciona con la clase ya que utilizo métodos de inferencia bayesiana y cadenas de Markov para el contexto, donde se aplica la regla de que el estado actual sólo depende del anterior.

## 2. Candidatos de palabras correctas

Modelando el sistema de corrección de palabras como se ha dicho con anterioridad, se requiere encontrar los candidatos que puedan maximizar la función decrita con anterioridad. Para esto es necesario generar dichos candidatos haciendo eliminaciones, inserciones, sustituciones y trasposiciones de letras en la palabra erronea. Eliminación se refiere a quitar una letra, sistitución a cambiar una letra por otra, inserción a agregar una letra y trasposición a cambiar de lugar una letra con otra en lugares contiguos.

Existe una medida de distancia entre palabras conocida como distancia de Damerau-Levenshtein la cual indica el número de modificaciones que se realizan a una palabra para generar otra. Por ejemplo, de "casa" a "caza" la distancia es 1, ya que sólo cambió una letra. En el caso de "casa" y "acza" sería 2, ya que hay una trasposición y una susutitución. Como se dijo con anterioridad, los errores más comunes son de distancia 1, por eso los candidatos que mayormente se generan se encuentran a esta distancia, seguida de los de distancia 2.

## 3. Modelos de lenguaje

## 4. Modelos de errores y ruido en el canal

## 5. Objetivo

El objetivo del presente proyecto es generar una aplicación basada en Shiny the R, que utilice el anterior modelo descrito para corregir texto. Se crearon dos versiones, una versión modelando el lenguaje por medio de unigramas y el segundo utilizando bigramas. La aplicación elaborada con Shiny también muestra a detalle el proceso de corregir las palabras.

## 6. Algoritmos y métodos

En ésta sección se relata el proceso que se llevó a cabo para generar los dos correctores ortográficos generados aquí. En ambos casos se utilizó un set de entrenamiento con 50,000 notas de periódico en español. Dichas notas fueron limpiadas de tal manera que todas las letras fueran minúsculas y los diferentes signos de puntuación y demás signos no alfa numéricos fueron removidos. Con este set de entrenamiento se contaron las frecuencias de cada unigrama y bigrama, después se calculó de acuerdo al número total de los mismos, la probabilidad de aparición en escala logarítmica.

Una vez contando con el los valores de frecuencias de los unigramas y bigramas se realizan los siguientes pasos. Todas las funciones de este proyecto fueron desarrolladas en R. En el caso de utilizar unigramas:

1. Encuentran las palabras erroneas en el texto de entrada.
2. Por cada palabra erronea se generan candidatos por medio de las cuatro operacion básicas mencionadas con anterioridad: eliminación, inserción, sustitución y trasposición.
3. De los posibles candidatos sólo quedarse con los que se encuentran en el vocabulario y desechar las demás.
4. Calcular la probabilidad del modelo de canal de ruido para cada candidato en escala logarítmica.
5. Sumar la probabilidad de aparición de dicha palabra con la probabilidad proveniente del modelo del canal.
6. Nos quedamos con la palabra que tenga una probabilidad mayor.

El modelo de unigramas es un modelo sencillo en la parte del modelo de lenguaje, donde sólo se considera la frecuencia de ocurrencia de las palabras. El modelo tiene la ventaja de ser rápido y con complejidad moderada, pero no tiene un buen desempeño cuando los errores son palabras que existen en el diccionario. Para resolver estos casos es necesario contar con contexto.

El modelo de lenguaje que utiliza bigramas se basa en la probabilidad condicional de que una palabra aparezca seguida de otra. Ésta es una manera de tener contexto ya que cada palabra depende de la anterior. Para que este algoritmo funcione es necesario contar con una probabilidad para cada palabra de que sea errónea ya que queremos atacar errores donde las palabras existen en el diccionario pero no van de acuerdo al contexto. Algunos ejemplos de estos casos, sería cuando en lugar de "casa" se escribe "caza". Ambas palabras existen en el diccionario pero se puede saber si son erróneas de acuerdo al contexto. El algoritmo de este modelo es:

1. Encuentran las palabras erróneas en el texto de entrada.
2. Por cada palabra se generan candidatos por medio de las cuatro operaciones básicas mencionadas con anterioridad: eliminación, inserción, sustitución y trasposición.
3. De los posibles candidatos sólo quedarse con los que se encuentran en el vocabulario y desechar los demás.
4. Por cada par de candidato y la palabra que antecede al error  $x$  calcular la frecuencia de su bigrama.
5. Por cada par de candidato y la palabra que le precede al error  $x$  calcular la frecuencia de su bigrama.
6. Multiplicar las frecuencias de ambos bigramas.
7. Calcular la probabilidad del modelo de canal de ruido para cada candidato en escala logarítmica.
8. Sumar la probabilidad de aparición de dicha palabra de acuerdo a los bigramas con la probabilidad proveniente del modelo del canal.
9. Nos quedamos con la palabra que tenga una probabilidad mayor.

En este modelo de lenguaje con bigramas se condiciona la aparición de la palabra que genera el error  $x$  a la palabra que le antecede y que le precede, esto ayuda a revisar las palabras por contexto. También es necesario agregar que se chequean todas las palabras como casos posibles de ser erróneas, por lo que como se ha explicado con anterioridad, todas las palabras son sospechosas de error ya que por contexto podrían estar mal.

## 7. Resultados

Adjunto a este reporte se presenta la aplicación desarrollada en Shiny. Ambos correctores fueron programados y se pueden probar.

## 8. Conclusiones

Utilizar un modelo del lenguaje con unigramas puede resolver problemas ortográficos donde las palabras no cuentan con contexto, puede considerarse una primera aproximación a los correctores ortográficos. El modelo es sencillo y rápido pero no puede detectar errores que caben en el vocabulario pero están mal empleadas, como son los errores fonéticos que dependen del sonido.

El modelo de lenguaje con bigramas es un poco más complejo pero puede ser útil para corregir palabras por contexto. El modelo se basa en la regla de Markov, donde el estado actual depende sólo del anterior y de inferencia bayesiana.

## Referencias

- [1] Kernighan, M. D., Church, K.W., and Gale, W. A. *A spelling correction program base on a noisy channel model*. In COLING-90, Helsinki, Vol. II, pp. 205–211, 1990.
- [2] Church, K. W. and Gale, W. A. *Probability scoring for spelling correction*. *Statistics and Computing*. 93–103, 1991.
- [3] Mays, E., Damerau, F. J., and Mercer, R. L. *Context based spelling correction*. *Information Processing and Management*. 517–522, 1990.